

ANALISIS DATA VIDEO GAME DI STEAM DENGAN CRISP-DM UNTUK PREDIKSI SENTIMEN GAME

Diajukan Sebagai Tugas Mata Kuliah
Analisis dan Pengolahan Data Digital



Nama: Kadek Yuni Suratri Nim: 2208561055
Nama: Kendrick Raphael Ticoalu Nim: 2208561097
Nama: Esa Sulistyo Aji Nugroho Nim: 2208561144

**PRODI INFORMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS UDAYANA
JUNI 2025**

DAFTAR ISI

DAFTAR ISI	ii
BAB I PENDAHULUAN	1
1.1. Latar Belakang.....	1
1.2. Rumusan Masalah.....	1
1.3. Tujuan Penelitian.....	2
BAB II TINJAUAN PUSTAKA	3
2.1. Tinjauan Empiris.....	3
2.2. Tinjauan Teoritis {penjelasan definisi dan sejarah}.....	4
2.2.1. Steam.....	4
2.2.2. CRISP-DM.....	4
2.2.3. Regresi.....	4
2.2.4. Rekayasa Fitur.....	5
BAB III PERANCANGAN DAN IMPLEMENTASI SISTEM	6
3.1. Metodologi {penjelasan langkah2 kinerja setiap teknik}.....	6
3.1.1. Data.....	6
3.1.2. CRISP-DM.....	6
3.1.3. Rekayasa Fitur.....	6
3.1.4. Model Regresi.....	7
3.2. Perancangan {penjelasan bagaimana teknik diterapkan dalam penelitian ini}	7
3.2.1. Business Understanding.....	7
3.2.2. Data Understanding.....	8
3.2.3. Data Preparation.....	9
3.2.4. Modelling.....	10
3.2.5. Evaluasi.....	11
3.3. Implementasi.....	11
BAB IV HASIL DAN PEMBAHASAN	16
4.1. Analisis dan Evaluasi Sistem.....	16
4.2. Pembahasan.....	21
BAB V KESIMPULAN DAN SARAN	23
5.1. Kesimpulan.....	23
5.2. Saran.....	23
DAFTAR PUSTAKA	24

BAB I PENDAHULUAN

1.1. Latar Belakang

Industri video game telah mengalami perkembangan yang sangat pesat seiring dengan kemajuan teknologi digital. Game tidak lagi hanya sekadar media hiburan, tetapi juga menjadi bagian dari budaya populer, sarana edukasi, hingga ladang ekonomi digital dengan nilai pasar miliaran dolar. Salah satu platform distribusi digital terbesar yang menjadi pusat aktivitas industri game saat ini adalah Steam. Steam menyediakan ribuan game dari berbagai genre dan memungkinkan pengguna untuk memberikan ulasan serta penilaian terhadap game yang mereka mainkan. Ulasan ini mencerminkan sentimen pengguna dan menjadi salah satu indikator penting bagi pengembang dalam mengevaluasi kualitas game mereka. Oleh karena itu, data yang dihasilkan dari platform ini menjadi sumber informasi yang sangat berharga untuk dianalisis lebih lanjut. Melalui analisis data video game di Steam, khususnya data ulasan pengguna, kita dapat menggali wawasan mendalam mengenai bagaimana persepsi pemain terhadap sebuah game. Dengan demikian, penelitian yang berfokus pada analisis data ulasan game di Steam untuk prediksi sentimen tidak hanya memberikan kontribusi terhadap pemahaman perilaku pengguna, tetapi juga mendukung pengembangan game yang lebih responsif terhadap kebutuhan dan keinginan pasar. Di tengah tingginya persaingan di industri game, pendekatan berbasis data seperti ini menjadi kunci dalam menciptakan produk yang lebih unggul dan diminati.

Penelitian ini mengajukan penerapan pendekatan CRISP-DM untuk menganalisis faktor-faktor yang mempengaruhi performa video game dari sisi Developer. Diharapkan hasil yang dicapai adalah penemuan faktor-faktor apa saja yang bisa dipertimbangkan dari sisi perusahaan game developer untuk memaksimalkan kepuasan konsumen terhadap video game.

1.2. Rumusan Masalah

Penelitian ini merangkai rumusan masalah berikut.

1. Bagaimana penerapan CRISP-DM dalam menganalisis kepuasan video game?

2. Bagaimana rekayasa fitur dalam menentukan fitur yang mempengaruhi kepuasan video game?
3. Bagaimana penerapan model regresi untuk memprediksi performa video game?

1.3. Tujuan Penelitian

Tujuan dari penelitian ini merupakan:

1. Membantu dalam memahami potensi keberhasilan suatu game.
2. Mengetahui bagaimana rekayasa fitur dalam menentukan fitur yang mempengaruhi kepuasan video game.
3. Memberikan rekomendasi akurat kepada pengguna seberapa besar seseorang menyukai suatu game.

BAB II TINJAUAN PUSTAKA

2.1. Tinjauan Empiris

2.1.1. Sentiment Analysis: Predicting Product Reviews for E-Commerce Recommendations Using Deep Learning and Transformers (Bellar et al., 2024)

Sebuah studi benchmark yang membandingkan model berbasis CNN, RNN, Bi-LSTM, dan Transformer (misalnya, BERT, FastText, Word2Vec) untuk memprediksi peringkat bintang dari ulasan pengguna di sebuah peritel pakaian wanita daring. Para penulis mengevaluasi pengaturan klasifikasi sentimen 3 kelas dan 5 kelas serta menyoroti keunggulan penyematan transformer dalam tugas prediksi peringkat.

2.1.2. A modernized approach to sentiment analysis of product reviews using BiGRU and RNN based LSTM deep learning models (Godlin Atlas et al., 2025)

Mengusulkan pipeline pembelajaran mendalam hibrida menggunakan BiGRU untuk ekstraksi fitur dan RNN-LSTM untuk klasifikasi sentimen tingkat kalimat (positif, netral, negatif) pada ulasan produk Amazon. Setelah preprocessing (tokenisasi, lemmatisasi, dll.), model ini mengungguli pendekatan berbasis CNN, MLP, CapsuleNet, dan bahkan GAN pada metrik evaluasi seperti F1 dan AUC.

2.1.3. Sentiment Analysis of Game Reviews on STEAM using BERT, BiLSTM, and CRF (Fadhlurrahman et al., 2023)

Menganalisis sentimen ulasan game Steam menggunakan beberapa model (BiLSTM, BiGRU, BERT). Kemudian, mereka meningkatkan kinerja dengan model BiLSTM-CRF menggunakan empat status tersembunyi BERT terakhir, mencapai skor F1 terbaik sebesar 95,2%—jauh lebih tinggi daripada BERT dasar (88%).

2.1.4. Enhancing churn forecasting with sentiment analysis of Steam reviews (Abdul-Rahman et al., 2024)

Integrates sentiment polarity from ~12,000 Steam game reviews into a churn-forecasting time-series model. Combining Vector Autoregression with SVM-based sentiment scores, they achieve 89% accuracy and reduce MAPE to 10.37%, demonstrating that sentiment signals can meaningfully improve predictions of user churn in software/gaming contexts.

2.2. Tinjauan Teoritis {penjelasan definisi dan sejarah}

2.2.1. Steam

SteamDB (Steam Database) adalah situs web pihak ketiga yang menyediakan informasi mendetail tentang data yang tersedia di platform distribusi game digital Steam. SteamDB bukan bagian resmi dari Valve (pengembang Steam), tetapi menggunakan Steam Web API dan data publik lainnya untuk menampilkan berbagai informasi yang berguna bagi pengguna dan pengembang game.

2.2.2. CRISP-DM

CRISP-DM (Cross Industry Standard Process for Data Mining) merupakan kerangka kerja yang sering digunakan oleh para peneliti dan praktisi data mining untuk menyelesaikan permasalahan berbasis data secara sistematis. Proses penelitian ini mengikuti enam tahap utama dalam CRISP-DM, yaitu: pemahaman bisnis, pemahaman data, persiapan data, pemodelan, evaluasi, dan penyebaran hasil (Astuti D, 2019).

2.2.3. Regresi

Analisis regresi adalah metode statistik yang digunakan untuk mempelajari hubungan antara satu atau lebih variabel independen dengan variabel dependen.

- Variabel dependen adalah variabel yang nilainya ingin di prediksi atau menjelaskan dalam analisis regresi. Variabel ini juga dikenal sebagai variabel respons atau variabel terikat. Dalam konteks analisis regresi, variabel dependen merupakan variabel yang nilainya dipengaruhi oleh atau bergantung pada variabel independen.
- Variabel independen, di sisi lain, adalah variabel yang digunakan untuk menjelaskan atau memprediksi nilai variabel dependen. Variabel ini juga dikenal sebagai variabel prediktor atau variabel bebas. Dalam analisis regresi, variabel independen dianggap sebagai variabel yang dapat menghasilkan perubahan pada variabel dependen.

Analisis regresi melibatkan penggunaan model matematis, seperti regresi linear sederhana atau regresi linear berganda, untuk menggambarkan hubungan tersebut. Dengan menggunakan teknik ini, kita dapat mengestimasi koefisien regresi yang mengindikasikan seberapa besar pengaruh variabel independen terhadap variabel dependen (Ruang Jurnal, 2020).

2.2.4. Rekayasa Fitur

Dalam konteks pemodelan data dan pembelajaran mesin, rekayasa fitur (feature engineering) bertujuan untuk menciptakan representasi data yang lebih informatif, relevan, dan bermakna bagi model. Tujuan dari proses ini adalah untuk menghasilkan fitur-fitur yang memiliki nilai kebaruan (novelty) — artinya tidak redundan atau duplikat dari fitur lain — dan memiliki kontribusi signifikan terhadap prediksi variabel target.

BAB III PERANCANGAN DAN IMPLEMENTASI SISTEM

3.1. Metodologi

3.1.1. Data

Data yang kami gunakan pada penelitian ini adalah data primer yang kami kumpulkan dengan melakukan web scraping website steamdb.info. Data yang kami gunakan berupa metadata dari 500 game berdasarkan puncak pemain paling tinggi. Metadata yang kami gunakan berupa jumlah followers game, jumlah puncak, rata-rata dan perkembangan jumlah pemain pada 1 bulan sebelumnya, jumlah penonton stream game pada website twitch.tv, jumlah orang yang memiliki game tersebut dan jumlah review bagus dan buruknya dalam bentuk persentase.

3.1.2. CRISP-DM

Dalam penelitian ini kami menggunakan prinsip proses CRIPS-DM. Proses ini kami implementasikan mulai dari business understanding dengan tujuan, rumusan masalah dan latar belakang penelitian. Data understanding dengan mengambil data mentah dengan web scraping untuk diproses lebih lanjut. Data preparation dengan merekayasa data agar dapat diproses oleh sistem. Modelling dengan menggunakan 3 model untuk task regresi dan membandingkan dan menggunakan yang kami temukan paling bagus. Evaluasi dengan mengukur MAE dan RMSE dari 3 model yang diterapkan.

3.1.3. Rekayasa Fitur

Rekayasa fitur merupakan tahap yang kami lakukan pada penelitian ini untuk membersihkan dan meningkatkan data berdasarkan konsiderasi kenyataan. Pertama yang kami lakukan adalah mengecek apakah ada data yang kosong. Pada dataset kami, kami temukan ada 2 tipe data yang rentang kosong yaitu bagian jumlah penonton stream pada website twitch.tv dan statistik jumlah dan perkembangan pemain.

Untuk data yang kosong di bagian statistik pemain, kami hapuskan langsung dari dataset karena menurut kami jika game tidak memiliki statistik dari bulan sebelumnya kurang realistis juga kami bisa mendapatkan data yang akurat untuk memprediksi sentimen pada bulan berikutnya. Sedangkan untuk data yang kosong di bagian penonton stream, kami isikan jumlah penonton dengan rata-rata kolom tersebut. Hal ini kami lakukan karena menurut kami, karena data tersebut diambil dari website berbeda, kemungkinan data penonton sudah ada dari website aslinya tetapi belum tertera pada steamdb, jadi kami gunakan rata-rata untuk mempresentasikannya.

3.1.4. Model Regresi

Disini kami bangun 3 model untuk task regresi yaitu XGBoost, random forest regression dan linear regression. Kami menggunakan 3 model untuk dapat melihat performa mereka dan juga dapat melihat model manakah yang paling cocok untuk task kami.

3.2. Perancangan

3.2.1. Business Understanding

Industri video game terus berkembang pesat dengan ribuan game baru dirilis setiap tahunnya. Di tengah persaingan yang ketat, penting bagi developer dan publisher untuk mengetahui bagaimana persepsi atau sentimen pengguna terhadap sebuah game, baik sebelum maupun setelah dirilis. Informasi ini dapat digunakan sebagai dasar pengambilan keputusan dalam pengembangan fitur, pemasaran, hingga strategi monetisasi.


Namun, akan menjadi suatu tantangan jika melakukan penilaian sentimen secara manual dari review pengguna. Membutuhkan waktu dan tenaga yang besar, serta sulit jika dilakukan secara real-time. Oleh karena itu, dibutuhkan sistem yang mampu memprediksi sentimen pengguna terhadap suatu game berdasarkan data statistik.

3.2.2. Data Understanding

Penelitian ini mengukur kepuasan dengan rasio pengguna yang merekomendasikan sebuah video game yang ditampilkan pada halaman video game tersebut sebagai berikut.




Penelitian ini ingin memeriksa pengaruh metrik-metrik yang bisa ditemukan pada setiap halaman video game sebagai berikut



Fitur	Tipe Data	Keterangan
web-scraper-order	object	Kolom yang dibuat langsung oleh web scraper yang berisikan nomor urut atau ID internal yang diterapkan oleh scraper untuk setiap baris data yang diekstrak
web-scraper-start-url	object	URL dari halaman awal tempat web scraper memulai proses
game	object	Nama game yang akan diakses
games-href	object	URL langsung ke halaman detail data game
followers	object	Jumlah orang yang mengikuti game tersebut
Twitch-viewers-24-hours	object	Jumlah orang yang melihat broadcast game di situs 'twitch' dalam 24 jam terakhir


Twitch-viewer-all-time	object	Jumlah total orang yang melihat broadcast di situs 'twitch'
owner-estimations-vg	object	Perkiraan jumlah orang yang memiliki suatu game berdasarkan vg
owner-estimations-SteamSpy	object	Perkiraan jumlah orang yang memiliki suatu game berdasarkan SteamSpy
owner-estimations-PlayTracker	object	Perkiraan jumlah orang yang memiliki suatu game berdasarkan PlayTracker
Month	object	Nama bulan sebelumnya

Penelitian ini menemukan faktor yang mempengaruhi kepuasan terhadap video game dengan menganalisis fitur pada data video game di Steam. Serta melakukan pengujian dengan penyusunan model dimana hasil evaluasi bisa menjadi landasan pembuktian pengaruh fitur terhadap kepuasan video game sebagai berikut.



3.2.3. Data Preparation

Data hasil web scraping akan dilakukan preprocessing dan rekayasa fitur sebagai berikut.



Data hasil web scraping masih berisi data bertipe string maka preprocessing dilakukan agar bisa membentuk tabel untuk kolom-kolom fitur dan kolom target dimana values bertipe data numerik. Dibentuk *feature space* dimana setiap aksis adalah sebuah fitur dimana penempatan data poin berdasarkan nilai value numerik pada kolom tersebut.

Rekayasa fitur dilakukan untuk menentukan fitur yang mempengaruhi variabel target. Selain itu setiap fitur tidak boleh saling berkorelasi tinggi agar bisa mencapai unsur novelty dimana setiap fitur membawa makna variatif terhadap variabel target rasio kepuasan pengguna.

3.2.4. Modelling

Penelitian ini melakukan pembuktian pengaruh fitur metrik video game terhadap kepuasan video game dengan menyusun model regresi untuk memprediksi tingkat kepuasan. Modelling dilakukan dengan teknik regresi standar sebagai berikut.

- **Linear Regresi:** Metode statistik yang digunakan untuk memodelkan hubungan antara variabel dependen dan satu atau lebih variabel independen dengan memasang garis lurus (atau bidang hiper dalam dimensi yang lebih tinggi) pada data. Model ini mengasumsikan hubungan ini linear, artinya keluaran dapat dinyatakan sebagai penjumlahan terbobot dari masukan ditambah suku bias. Metode ini meminimalkan galat kuadrat rata-rata antara nilai prediksi dan nilai aktual menggunakan metode seperti kuadrat terkecil biasa. Meskipun sederhana dan dapat diinterpretasikan, model ini mungkin berkinerja buruk ketika data memiliki pola yang kompleks atau non-linear.
- **Random Forest:** Random Forest adalah metode pembelajaran ensemble yang membangun beberapa pohon keputusan selama pelatihan dan menggabungkan keluarannya (berdasarkan suara mayoritas untuk klasifikasi atau rata-rata untuk regresi) untuk meningkatkan akurasi dan mengurangi overfitting. Setiap pohon dilatih pada subset acak dari data dan fitur, sehingga menghasilkan keragaman dan menurunkan varians dibandingkan dengan pohon keputusan tunggal. Keacakan ini, dikombinasikan dengan pendekatan ensemble, menjadikan

Random Forest tangguh, relatif mudah diinterpretasikan, dan efektif untuk berbagai tugas, terutama ketika data memiliki hubungan non-linier.

- **eXtreme Gradient Boosting:** eXtreme Gradient Boosting atau XGBoost adalah algoritma pembelajaran mesin yang canggih berdasarkan penguatan gradien, yang membangun sekumpulan pohon keputusan secara berurutan, di mana setiap pohon baru mengoreksi kesalahan yang dibuat oleh pohon sebelumnya. Algoritma ini menggunakan fungsi kerugian khusus dan teknik regularisasi untuk mencegah overfitting, sehingga sangat efektif untuk data terstruktur/tabular. XGBoost dikenal karena kecepatan, skalabilitas, dan kemampuannya dalam menangani data yang hilang serta pemeringkatan kepentingan fitur. Performanya seringkali mengungguli model yang lebih sederhana dalam kompetisi dan aplikasi dunia nyata.

3.2.5. Evaluasi

Penelitian ini menguji performa model regresi dengan membandingkan nilai eror dimana evaluasi bermakna baik dengan nilai eror yang lebih kecil. Digunakan metric evaluasi berikut.

3.3. Implementasi

Penghapusan kolom-kolom metadata dilakukan sebagai berikut

```
df = df.drop(['web-scraper-order', 'web-scraper-start-url', 'game', 'game-href', 'Month'],  
axis=1)
```

Tahap preprocessing dimana dilakukan parsing integer terhadap data string dimana tanda koma, negatif, dan penanda tingkat (M, k) diperhitungkan diimplementasikan sebagai berikut.

```
import re  
  
df_int = df.copy()  
  
def parse_number(s):
```

```

if not isinstance(s, str):
    return None
s = s.replace(',', '').replace(' ', '')

match = re.findall(r'(-?\d.+)([kKmM]?)', s)

if match:
    num, suffix = match[0]
    try:
        n = float(num)
        if suffix.lower() == 'k':
            n *= 1_000
        elif suffix.lower() == 'm':
            n *= 1_000_000
        return int(n)
    except:
        return None
return None

for col in df_int.select_dtypes(include='object').columns:
    df_int[col] = df_int[col].apply(parse_number)

df_int.head()

```

Penghapusan barisan berdasarkan kehadiran missing values sebagai berikut.

```

df_filled.dropna(subset=['user-reviews'], how='all', inplace=True)

cols_to_drop_na = ['Peak', 'Gain', 'Gain-pct', 'Average', 'Avg-Gain-pct']
df_filled.dropna(subset=cols_to_drop_na, inplace=True)

```

Imputasi nilai kosong dengan angka mean kolom tersebut dilakukan sebagai berikut.

```

cols_to_fill_mean = ['followers', 'twitch-viewers-24-hours', 'twitch-viewers-all-time',
'owner-estimations-vg', 'owner-estimations-SteamSpy',
'owner-estimations-PlayTracker']
for col in cols_to_fill_mean:

```

```
if col in df_filled.columns:  
    df_filled[col].fillna(df_filled[col].mean(), inplace=True)
```

Korelasi antar fitur diperiksa dengan metode `corr()` dari kelas `pandas`. Pemeriksaan fitur yang saling berkorelasi sebagai berikut.

```
correlation_matrix = df_filled.corr()  
  
user_reviews_correlation = correlation_matrix['user-reviews'].drop('user-reviews')  
  
high_inter_correlation_pairs = []  
threshold_inter = 0.8  
  
for i in range(len(correlation_matrix.columns)):  
    for j in range(i + 1, len(correlation_matrix.columns)):  
        col1 = correlation_matrix.columns[i]  
        col2 = correlation_matrix.columns[j]  
        if abs(correlation_matrix.iloc[i, j]) >= threshold_inter and col1 != 'user-reviews'  
and col2 != 'user-reviews':  
            high_inter_correlation_pairs.append((col1, col2))  
  
correlated_pairs_with_similar_user_reviews_corr = []  
threshold_user_reviews_similarity = 0.01  
  
for col1, col2 in high_inter_correlation_pairs:  
    corr1_user_reviews = user_reviews_correlation.get(col1, 0)  
    corr2_user_reviews = user_reviews_correlation.get(col2, 0)  
    if abs(corr1_user_reviews - corr2_user_reviews) <=  
threshold_user_reviews_similarity:  
        correlated_pairs_with_similar_user_reviews_corr.append((col1, col2))  
  
highly_correlated_and_similarly_user_reviews_correlated_pairs =  
correlated_pairs_with_similar_user_reviews_corr  
  
highly_correlated_and_similarly_user_reviews_correlated_pairs
```

Penggabungan kolom-kolom berkorelasi dengan angka mean diimplementasikan sebagai berikut.

```

columns_to_merge_pairs = [
    ('twitch-viewers-24-hours', 'twitch-viewers-all-time'),
    ('Peak', 'Average'),
    ('Gain-pct', 'Avg-Gain-pct')
]

for col1, col2 in columns_to_merge_pairs:
    new_col_name = f'{col1}_{col2}_mean'
    df_important_features[new_col_name] = df_important_features[[col1,
col2]].mean(axis=1)
    df_important_features = df_important_features.drop([col1, col2], axis=1)

columns_to_merge_trio = ['owner-estimations-vg', 'owner-estimations-SteamSpy',
'owner-estimations-PlayTracker']
new_col_name_trio = '_'.join(columns_to_merge_trio) + '_mean'
df_important_features[new_col_name_trio] =
df_important_features[columns_to_merge_trio].mean(axis=1)
df_important_features = df_important_features.drop(columns_to_merge_trio, axis=1)

df_important_features.head()
df_important_features.columns

```

Training dan testing model regresi untuk memprediksi rasio kepuasan video game berdasarkan nilai fitur penting diimplementasi sebagai berikut

```

xgb = XGBRegressor(random_state=42).fit(X_train, y_train)
y_pred_xgb = xgb.predict(X_test)

```

Evaluasi perbandingan performa model regresi dilakukan sebagai berikut

```

target_col = 'user-reviews'
features = [col for col in df_important_features.columns if col != target_col and
df_important_features[col].dtype in [np.int64, np.float64]]

results = []

n = int(len(df_important_features))
X = df_important_features[features].iloc[:n].fillna(0)

```



```

y = df_important_features[target_col].iloc[:n].fillna(0)
X_train, X_test, y_train, y_test = X, X, y, y # Use all for both train/test for fair
comparison
# Linear Regression
lr = LinearRegression().fit(X_train, y_train)
y_pred_lr = lr.predict(X_test)
mae_lr = mean_absolute_error(y_test, y_pred_lr)
rmse_lr = root_mean_squared_error(y_test, y_pred_lr)
results.append({'Model': 'LinearRegression', 'MAE': mae_lr, 'RMSE': rmse_lr})
# Random Forest
rf = RandomForestRegressor(random_state=42).fit(X_train, y_train)
y_pred_rf = rf.predict(X_test)
mae_rf = mean_absolute_error(y_test, y_pred_rf)
rmse_rf = root_mean_squared_error(y_test, y_pred_rf)
results.append({'Model': 'RandomForest', 'MAE': mae_rf, 'RMSE': rmse_rf})
# XGBoost (if available)
if xgb_available:
    xgb = XGBRegressor(random_state=42).fit(X_train, y_train)
    y_pred_xgb = xgb.predict(X_test)
    mae_xgb = mean_absolute_error(y_test, y_pred_xgb)
    rmse_xgb = root_mean_squared_error(y_test, y_pred_xgb)
    results.append({'Model': 'XGBoost', 'MAE': mae_xgb, 'RMSE': rmse_xgb})

```

BAB IV HASIL DAN PEMBAHASAN

4.1. Analisis dan Evaluasi Sistem

Hasil web scraping disimpan dalam dataframe sehingga bisa ditampilkan sebagai berikut.

	web-scrapers-order	web-scrapers-start-url	game	game-kref	followers	twitch-viewers-24-hours	twitch-viewers-all-time	owner-estimations-vg	owner-estimations-SteamSpy	owner-estimations-PlayTracker	Month	Peak	Gain	Gain-pct	Average	Avg-Gain-pct	user-reviews
0	1751940014-1	https://steamdb.info/charts/sort=peak	Sultan's Game	https://steamdb.info/app/3117820/charts/	55,412	117	13,662	-491.3 k	-719.2 k	-1.01 M	June 2025	16,432	-5,100	-23.70%	5,242	-36.30%	92.50%
1	1751940020-2	https://steamdb.info/charts/sort=peak	HoloCure - Save the Fans!	https://steamdb.info/app/2420510/charts/	34,146	52	26,519	-917.3 k	-1.15 M	-1.89 M	June 2025	1,123	-173	-13.30%	694	-14.00%	96.99%
2	1751940026-3	https://steamdb.info/charts/sort=peak	Like a Dragon: Infinite Wealth	https://steamdb.info/app/2072450/charts/	48,734	324	76,294	-500.1 k	-600.0 k	-605.2 k	June 2025	1,720	-458	-21.00%	760	-27.10%	89.46%
3	1751940031-4	https://steamdb.info/charts/sort=peak	Call of Duty®: Modern Warfare® 3 (2011)	https://steamdb.info/app/42680/charts/	74,209	-3.61 M	-4.09 M	74,209	259	412	June 2025	536	+70	+15.0%	286	+16.7%	NaN
4	1751940037-5	https://steamdb.info/charts/sort=peak	Core Keeper	https://steamdb.info/app/1821690/charts/	156,996	1,172	54,513	-1.69 M	-2.98 M	-3.42 M	June 2025	8,223	+305	+3.9%	3,549	-10.30%	91.26%

Kolom-kolom metadata seperti nama, link URL, dan sebagainya di hapuskan sehingga tersisa kolom-kolom fitur dan target sebagai berikut.

	followers	twitch-viewers-24-hours	twitch-viewers-all-time	owner-estimations-vg	owner-estimations-SteamSpy	owner-estimations-PlayTracker	Peak	Gain	Gain-pct	Average	Avg-Gain-pct	user-reviews
0	55,412	117	13,662	-491.3 k	-719.2 k	-1.01 M	16,432	-5,100	-23.70%	5,242	-36.30%	92.50%
1	34,146	52	26,519	-917.3 k	-1.15 M	-1.89 M	1,123	-173	-13.30%	694	-14.00%	96.99%
2	48,734	324	76,294	-500.1 k	-600.0 k	-605.2 k	1,720	-458	-21.00%	760	-27.10%	89.46%
3	74,209	-3.61 M	-4.09 M	74,209	259	412	536	+70	+15.0%	286	+16.7%	NaN
4	156,996	1,172	54,513	-1.69 M	-2.98 M	-3.42 M	8,223	+305	+3.9%	3,549	-10.30%	91.26%

Kolom-kolom tersebut yang masih berisi data bertipe string diubah menjadi data numerik sehingga menjadi berikut.

	followers	twitch-viewers-24-hours	twitch-viewers-all-time	owner-estimations-vg	owner-estimations-SteamSpy	owner-estimations-PlayTracker	Peak	Gain	Gain-pct	Average	Avg-Gain-pct	user-reviews
0	55412.0	117.0	13662.0	491300.0	719200.0	1010000.0	16432	-5100.0	-23.0	5242.0	-36.0	92.0
1	34146.0	52.0	26519.0	917300.0	1150000.0	1890000.0	1123	-173.0	-13.0	694.0	-14.0	96.0
2	48734.0	324.0	76294.0	500100.0	600000.0	605200.0	1720	-458.0	-21.0	760.0	-27.0	89.0
3	74209.0	3610000.0	4090000.0	74209.0	259.0	412.0	536	70.0	15.0	286.0	16.0	NaN
4	156996.0	1172.0	54513.0	1690000.0	2980000.0	3420000.0	8223	305.0	3.0	3549.0	-10.0	91.0

Ditemukan missing values untuk setiap kolom sebagai berikut.

	0
followers	6
twitch-viewers-24-hours	12
twitch-viewers-all-time	13
owner-estimations-vg	12
owner-estimations-SteamSpy	12
owner-estimations-Play Tracker	17
Peak	0
Gain	4
Gain-pct	4
Average	1
Avg-Gain-pct	4
user-reviews	15

Kolom variabel target (y) yaitu user-reviews bisa terdapat missing values. Karena ditemukan bahwa platform steam terdapat video game yang sudah dicabut halamannya.

Dead Island	https://steamdb.info/app/19789/	19,789	~10.25 M	19,789	9	43	June 2025	64	-9	-12.30%	27	+0.0%	
XCOM: Chimera Squad	https://steamdb.info/app/41604/	41,604	~683.6 k	~774.6 k	~1.18 M		June 2025	152	-3	-1.90%	73	-13.10%	70.48%


Saat mencoba untuk mencari game dengan judul “Dead Island”, tidak bisa ditemukan karena akses diprivat.

Dead Island		Search	Sort by Relevance
748 results match your search. 10 titles have been excluded based on your preferences. However, none of these titles would appear on the first page of results.			
	Dead Island 2	22 Apr. 2024	Rp 534 000
	Dead Island Definitive Edition	31 May. 2016	Rp 214 000
	Escape Dead Island	21 Nov. 2014	Rp 161 000
	Dead Island Retro Revenge	1 Jun. 2016	Rp 54 000
Dead Island Definitive Collection			


Dihapuskan barisan-barisan yang tidak memiliki nilai pada kolom user-reviews sehingga tersisa missing values berikut.

	0
followers	0
twitch-viewers-24-hours	1
twitch-viewers-all-time	1
owner-estimations-vg	2
owner-estimations-SteamSpy	2
owner-estimations-PlayTracker	6
Peak	0
Gain	2
Gain-pct	2
Average	0
Avg-Gain-pct	2
user-reviews	0

Kolom-kolom siaran twitch dan estimasi pemilik (owner) sesungguhnya merupakan informasi opsional sehingga tidak selalu ditampilkan karena belum dilacak/dihubungkan dengan platform third party.



Game a




Game b

Kolom-kolom gain yaitu data kenaikan jumlah pemain bulan ini dari bulan sebelumnya bisa hilang karena video game tersebut sudah baru dirilis.


Release Date	10 June 2025 – 14:00:00 UTC (31 days ago)
--------------	---

Kolom-kolom siaran Twitch dan estimasi pemilik diisi nilai mean kolom, serta dihapus barisan dengan kolom-kolom gain kosong. Maka tidak ada sisa missing values.

Ditemukan bahwa konsentrasi video game dengan kepuasan lebih tinggi yang disebabkan oleh bias pemain untuk hanya memainkan video game yang sudah menarik atau disukai konsumen.




Hasil pemeriksaan korelasi sebagai berikut.



Ditemukan bahwa fitur-fitur yang saling berkorelasi sebagai berikut.

[('owner-estimations-vg', 'owner-estimations-SteamSpy'),
 ('owner-estimations-vg', 'owner-estimations-PlayTracker'),
 ('owner-estimations-SteamSpy', 'owner-estimations-PlayTracker'),
 ('Peak', 'Average')]

Kolom-kolom itu digabung menjadi kolom yang berisi mean sehingga korelasi tabel baru sebagai berikut.



Maka hasil rekayasa fitur yang digunakan ialah

```
[ 'followers', 'Gain', 'user-reviews',
  'twitch-viewers-24-hours_twitch-viewers-all-time_mean',
  'Peak_Average_mean', 'Gain-pct_Avg-Gain-pct_mean',
  'owner-estimations-vg_owner-estimations-SteamSpy_owner-estimations-PlayTracker_mean']
```

Model regresi mampu melakukan prediksi user-reviews yaitu tingkat kepuasan berdasarkan fitur tersebut seperti berikut.

```
[33] X_test.iloc[0]
followers      55412.000000
Gain          -5100.000000
twitch-viewers-24-hours_twitch-viewers-all-time_mean  6889.500000
Peak_Average_mean  10837.000000
Gain-pct_Avg-Gain-pct_mean -29.500000
owner-estimations-vg_owner-estimations-SteamSpy_owner-estimations-PlayTracker_mean  740166.666667
dtype: float64

[34] y_test.iloc[0]
np.float64(92.0)

X_test_first_row = X_test.iloc[[0]]
y_pred_xgb = xgb.predict(X_test_first_row)
y_pred_xgb
print(f"Predicted: {y_pred_xgb[0]}, Actual: {y_test.iloc[0]}")
Predicted: 91.99945831298828, Actual: 92.0
```

Perbandingan model regresi dalam memprediksi tingkat kepuasan data testing adalah sebagai berikut.

	Model	MAE	RMSE
0	LinearRegression	10.209282	12.767920
1	RandomForest	4.043232	4.994123
2	XGBoost	0.000640	0.000897

4.2. Pembahasan

Rekayasa fitur dilakukan untuk menangani multikolinearitas dan meningkatkan kualitas prediksi. Sebagai contoh, kolom-kolom estimasi pemilik dari berbagai sumber (vg, SteamSpy, PlayTracker) digabung menjadi satu kolom mean untuk meminimalkan pengaruh redundansi data. Demikian pula, kolom Peak dan Average pemain juga digabung menjadi satu kolom mean.

Analisis korelasi menunjukkan adanya fitur-fitur yang memiliki hubungan saling berkorelasi tinggi, seperti antara estimasi pemilik dari beberapa sumber dan antara jumlah pemain puncak (Peak) dengan jumlah pemain rata-rata (Average).

Setelah penggabungan kolom yang berkorelasi tersebut, diperoleh fitur-fitur akhir yang digunakan sebagai prediktor kepuasan, yaitu:

- Followers
- Gain (kenaikan jumlah pemain)
- Twitch-viewers-24-hours_twitch-viewers-all-time_mean
- Peak_Average_mean
- Gain-pct_Avg-Gain-pct_mean
- owner-estimations-vg_owner-estimations-SteamSpy_owner-estimations-PlayTracker_mean

Temuan ini mendukung hipotesis awal bahwa kepuasan pengguna tidak hanya dipengaruhi oleh kualitas game itu sendiri, tetapi juga oleh popularitas, tren, dan tingkat keterlibatan komunitas.

Analisis juga menemukan adanya bias: game yang populer cenderung memiliki kepuasan lebih tinggi, sehingga model dapat belajar pola yang didominasi oleh popularitas daripada kualitas intrinsik game. Selain itu, data yang digunakan hanya terbatas pada game yang masih tersedia di Steam, sedangkan game yang sudah dihapus atau di private tidak dapat dianalisis.

Model regresi dibangun untuk memprediksi user-reviews sebagai proksi tingkat kepuasan. Tiga model diuji: Linear Regression, Random Forest, dan XGBoost. Linear Regression memiliki MAE sebesar 10.21 dan RMSE sebesar 12.76, yang relatif tinggi, menandakan model ini kurang mampu menangkap kompleksitas data. Random Forest menurunkan MAE menjadi sekitar 4.04 dan RMSE menjadi 4.99, menunjukkan model ini lebih baik dalam mempelajari hubungan non-linear. XGBoost memiliki MAE dan RMSE yang sangat rendah (0.0006 dan 0.0009), yang mengindikasikan model ini mampu belajar pola data dengan sangat baik. Namun, nilai error yang terlalu rendah juga patut dicurigai sebagai indikasi overfitting, mengingat data test set mungkin terlalu sesuai dengan data latih. Bisa disimpulkan bahwa model regresi bisa berperforma lebih baik seiring dengan kompleksitas kalkulasi.

BAB V KESIMPULAN DAN SARAN

5.1. Kesimpulan

Berdasarkan hasil penelitian dan analisis yang telah dilakukan, dapat disimpulkan bahwa tingkat kepuasan pengguna terhadap video game di platform Steam dapat diprediksi dengan cukup baik menggunakan model regresi berbasis fitur-fitur seperti jumlah pengikut (followers), kenaikan jumlah pemain (gain), eksposur di platform streaming Twitch, estimasi jumlah pemilik, serta statistik pemain puncak dan rata-rata. Model XGBoost terbukti memberikan performa prediksi terbaik dibandingkan Linear Regression dan Random Forest, meskipun perlu diwaspadai potensi overfitting. Penelitian ini juga menunjukkan bahwa kepuasan pengguna tidak hanya dipengaruhi oleh kualitas konten game itu sendiri, tetapi juga oleh faktor popularitas, tren pertumbuhan komunitas, dan visibilitas game di berbagai platform.

5.2. Saran

Untuk penelitian selanjutnya, disarankan untuk menggunakan dataset yang lebih luas dan mencakup periode waktu yang lebih panjang agar dapat menangkap dinamika tren secara lebih komprehensif; Menambahkan variabel lain yang bersifat kualitatif, seperti genre, harga, atau penilaian kritikus, untuk melihat pengaruhnya terhadap kepuasan pengguna; Mempertimbangkan teknik validasi yang lebih ketat, seperti cross-validation, untuk meminimalkan risiko overfitting terutama pada model kompleks seperti XGBoost; Mengkaji lebih dalam bias popularitas yang muncul, misalnya dengan memisahkan analisis antara game baru dan game lama atau antara game indie dan AAA.

DAFTAR PUSTAKA

Abdul-Rahman, S., Ali, M.F.A.M., Bakar, A.A. et al. Enhancing churn forecasting with sentiment analysis of steam reviews. *Soc. Netw. Anal. Min.* 14, 178 (2024). <https://doi.org/10.1007/s13278-024-01337-3>

Atlas, L.G., Arockiam, D., Muthusamy, A. et al. A modernized approach to sentiment analysis of product reviews using BiGRU and RNN based LSTM deep learning models. *Sci Rep* 15, 16642 (2025). <https://doi.org/10.1038/s41598-025-01104-0>

Bellar, O., Baina, A., & Ballafkih, M. (2024). Sentiment Analysis: Predicting Product Reviews for E-Commerce Recommendations Using Deep Learning and Transformers. *Mathematics*, 12(15), 2403. <https://doi.org/10.3390/math12152403>

J. Al Mursyidy Fadhlurrahman, N. A. Herawati, H. R. Widya Aulya, I. Puspasari and N. P. Utama, "Sentiment Analysis of Game Reviews on STEAM using BERT, BiLSTM, and CRF," 2023 International Conference on Electrical Engineering and Informatics (ICEEI), Bandung, Indonesia, 2023, pp. 1-6, doi: 10.1109/ICEEI59426.2023.10346219.

Saputri, F. A., & Sari, S. (2023). Penentuan Strategi Promosi Usaha Mikro Kecil dan Menengah (UMKM) Menggunakan Metode CRISP-DM dengan Algoritma K-Means Clustering. *View of Penentuan Strategi Promosi UMKM*. Retrieved from <https://ejournal.upi.edu/index.php/viewofumkm> (Sesuaikan URL asli artikel jika berbeda)

Ruang Jurnal. (2023). Analisis Regresi: Definisi, Tujuan, Fungsi, dan Metode. *RuangJurnal*. <https://ruangjurnal.com/analisis-regresi-definisi-tujuan-fungsi-dan-metode>